

Optimalisasi Decision Tree dalam Prediksi Klasifikasi Cuaca menggunakan Random Forest

Rakhmadiani Ardinda Chaerunnisa¹, Siroj Munir², Naufal Afif Alfadhil³

¹Fakultas Teknologi Informasi dan Sains Data, Universitas Sebelas Maret, Surakarta, email: rakhmadianiardinda@student.uns.ac.id

²Fakultas Teknologi Informasi dan Sains Data, Universitas Sebelas Maret, Surakarta, email: munir_thesiroj@student.uns.ac.id

³Fakultas Teknologi Informasi dan Sains Data, Universitas Sebelas Maret, Surakarta, email: naufalfadhiluns@student.uns.ac.id

Abstract

Weather prediction is closely related to determining factors such as air temperature, humidity, wind speed, rainfall, cloud cover, atmospheric pressure, UV index, season, visibility, and location. One way to determine weather prediction is by using machine learning. The purpose of this research is to compare the results of weather prediction accuracy using three models, namely Decision Tree, Random Forest, and Random Forest which is carried out hyperparameter tuning with Grid Search Cross Validation. The data used is sourced from the kaggle site with 10 predictor variables and one response variable. In its application, the Decision Tree algorithm produces accuracy that can still be improved in predicting weather, namely by using Random Forest. The percentage of accuracy obtained using Random Forest is 90.98%. To increase the accuracy of the prediction, the model can be modified again by using the Grid Search Cross Validation hyperparameter tuning technique which aims to find the best hyperparameter set. This hyperparameter set is able to increase the model accuracy rate to 91.63%. Based on this research, it is found that the prediction model with the best accuracy level is Random Forest with a predetermined hyperparameter set.

Keywords: Prediction, Accuracy, Decision Tree, Random Forest, Hyperparameter Tuning.

Abstrak

Prediksi cuaca sangat erat kaitannya dengan faktor-faktor penentu seperti suhu udara, kelembapan, kecepatan angin, curah hujan, tutupan awan, tekanan atmosfer, indeks UV, musim, jarak pandang, serta lokasi. Salah satu cara untuk menentukan prediksi cuaca adalah dengan menggunakan *machine learning*. Tujuan dari penelitian ini adalah untuk membandingkan hasil akurasi prediksi cuaca menggunakan tiga model yakni *Decision Tree*, *Random Forest*, serta *Random Forest* yang dilakukan *hyperparameter tuning* dengan *Grid Search Cross Validation*. Data yang digunakan bersumber dari situs kaggle dengan terdapat 10 variabel prediktor dan satu variabel respon. Dalam penerapannya, algoritma *Decision Tree* menghasilkan akurasi yang masih dapat ditingkatkan lagi dalam memprediksi cuaca, yaitu dengan penggunaan *Random Forest*. Persentase akurasi yang didapatkan dengan menggunakan *Random Forest* adalah sebesar 90,98%. Untuk menambah keakuratan prediksi, model dapat dimodifikasi lagi dengan menggunakan teknik *hyperparameter tuning Grid Search Cross Validation* yang bertujuan untuk mencari *hyperparameter set* terbaik. *Hyperparameter set* ini mampu meningkatkan tingkat akurasi model menjadi 91,63%. Berdasarkan penelitian ini, didapatkan hasil bahwa model prediksi dengan tingkat akurasi terbaik adalah *Random Forest* dengan *hyperparameter set* yang sudah ditentukan.

Kata kunci: Prediksi, Akurasi, *Decision Tree*, *Random Forest*, *Hyperparameter Tuning*.

1. PENDAHULUAN

Perubahan cuaca yang tidak menentu dapat menjadi tantangan besar bagi kegiatan manusia. Dampak yang dihasilkan dari ketidakpastian cuaca sedikit banyak mampu menghambat berbagai kegiatan, seperti penundaan transportasi hingga bencana alam yang datang secara tiba-tiba. Hal ini menyebabkan berkurangnya tingkat produktivitas dan meningkatnya resiko kerugian. Salah satu solusi untuk mencegah atau mengurangi masalah yang timbul akibat ketidakpastian cuaca adalah dengan memprediksi cuaca. Prediksi cuaca tidak hanya membantu manusia dalam merencanakan aktivitasnya, melainkan juga menjadi faktor penting dalam mencegah resiko seperti bencana alam.

Dunia saat ini sudah mencapai tingkat kemajuan teknologi yang sangat luar biasa. Pendekatan berbasis *machine learning* menjadi salah satu solusi dalam memprediksi cuaca dengan tingkat akurasi yang tinggi. *Machine learning* adalah suatu algoritma berbasis *learn from data*, yang menggunakan data lampau untuk melakukan pembelajaran model agar dapat menghasilkan kemampuan yang optimal dalam menghasilkan keputusan [25]. Terdapat tiga bagian dari *machine learning* yakni *supervised learning*, *unsupervised learning*, serta *reinforcement learning* [25].

Penelitian terkait prediksi cuaca, sebelumnya pernah dilakukan oleh peneliti lain yang dipublikasikan dalam jurnal dengan judul “Optimizing Rain Prediction Model Using Random Forest and Grid Search Cross-Validation for Agriculture Sector” [17]. Dalam penelitian ini, digunakan sembilan variabel yakni kelembapan rata-rata (RH avg), rata-rata kecepatan angin (ff avg), suhu udara minimum (Tn), suhu udara maksimum (Tx), suhu udara rata-rata (Tavg), arah angin (ddd x), curah hujan (RR), ff x, serta ss. Namun, keterangan variabel ff x dan ss tidak dijelaskan dalam data. Hasil penelitian ini didapatkan akurasi sebesar 79,91% menggunakan *Random Forest* dan *hyperparameter tuning* dengan *grid search cross-validation*. Namun, tidak dijelaskan *hyperparameter set* yang digunakan apa saja, sehingga pengamat tidak dapat membandingkan perbedaan akurasi antar *hyperparameter set* yang berbeda. Pada penelitian yang kami lakukan, kami menggunakan dataset yang berbeda dan akan menjabarkan tingkat akurasi pada masing-masing *hyperparameter set* sampai didapatkan nilai akurasi yang paling optimal.

Decision Tree merupakan *supervised machine learning* yang memiliki kemampuan untuk melakukan klasifikasi dan prediksi. Cara kerja *Decision Tree* adalah dengan menggunakan struktur pohon yang di mana simpul-simpul keputusan terhubung oleh cabang-cabang, dimulai dari simpul akar hingga simpul daun [26]. Algoritma *Decision Tree* dikenal memiliki interpretabilitas tinggi dan mampu menangani berbagai tipe data dengan baik. Namun, apabila algoritma ini digunakan dalam dataset yang kompleks, maka akan cenderung mengalami *overfitting* yakni keadaan di mana data *training* terlalu sesuai dengan model, sehingga mengurangi kemampuan untuk menggeneralisasi data baru atau data *testing* [27]. Masalah *overfitting* ini mampu diselesaikan dengan menggunakan algoritma *Random Forest* [28]. Dalam penelitian ini, algoritma *Decision Tree* mampu menghasilkan akurasi sebesar 90,64% dalam memprediksi cuaca. Sesuai dengan judul penelitian, yakni berkaitan dengan pengoptimalan algoritma *Decision Tree* menggunakan algoritma *Random Forest*, maka pembuatan model dilanjutkan dengan algoritma *Random Forest* guna meningkatkan persentase akurasi prediksi.


Random Forest adalah metode klasifikasi dengan memilih data dan variabel secara acak untuk menggabungkan beberapa pohon keputusan [2]. Algoritma *Random Forest* menggunakan sistem *voting* dari beberapa *Decision Tree* untuk menghasilkan keputusan kelas klasifikasi yang didapatkan dari *Decision Tree* yang memiliki suara terbanyak [2]. Dalam penerapan di penelitian ini, *Random Forest* mampu memprediksi data dengan tingkat akurasi 90,98%. Nilai akurasi ini masih belum meningkat jauh dari nilai akurasi dengan algoritma *Decision Tree*, maka dari itu nilai akurasi model harus ditingkatkan lagi dengan menggunakan *hyperparameter tuning*.

Hyperparameter merupakan pengaturan yang digunakan untuk mengatur dan mengendalikan proses pelatihan model [28]. Untuk menghasilkan kinerja model yang terbaik dilakukan proses yang disebut dengan *tuning*. *Tuning* bekerja dengan mencari kombinasi *hyperparameter* paling optimal [28]. Cara kerja dari *hyperparameter tuning* adalah dengan menguji *hyperparameter* secara berulang kali sampai mendapatkan nilai yang optimal [2]. Penelitian ini menggunakan *grid search cross-validation* untuk menemukan *hyperparameter set* terbaik.

Grid search cross-validation bekerja dengan cara memindai sejumlah *hyperparameter* kemudian menerapkannya pada model dan mengevaluasi performa dari setiap *hyperparameter set* dengan menggunakan *cross-validation*. *Hyperparameter set* yang memiliki performa terbaik akan terpilih sebagai *hyperparameter* yang digunakan pada model [2]. Pada penelitian ini, didapatkan hasil bahwa *n* estimator terbaik adalah berjumlah 100, max depth terbaik sejumlah 20, serta min sample split terbaik sejumlah 10. *Hyperparameter set* ini mampu meningkatkan tingkat akurasi model menjadi 91,63%.

2. METODE

Penelitian ini menggunakan algoritma *Decision Tree* yang dioptimalisasi dengan algoritma *Random Forest* dengan melakukan *hyperparameter tuning Grid Search Cross Validation*. Gambar 1 menunjukkan proses yang dilakukan dalam penelitian ini.




Gambar 1. Alur penelitian

2.1. DATA COLLECTION

Dalam proses pengumpulan data, pemilihan dataset yang baik sangat penting dilakukan untuk memastikan hasil analisis yang valid dan akurat. Dataset yang digunakan harus memiliki struktur yang baik dengan fitur-fitur (*features*) yang mewakili kondisi cuaca, sehingga memadai untuk dimodelkan menggunakan algoritma *machine learning*. Variabel-variabel dalam dataset dapat dikelompokkan menjadi dua kategori yaitu variabel input dan variabel output.

2.2. DATA ANALYSIS

Exploratory Data Analysis (EDA) merupakan cara untuk memahami dataset dengan melakukan eksplorasi data berdasarkan teknik aritmatika statistik dasar dan memvisualisasikan ringkasan eksplorasi dalam grafik yang tepat [4][5].



Gambar 2. Tahapan EDA

Pemeriksaan tipe data merupakan tahap untuk mengetahui tipe data dari masing-masing variabel pada dataset yang terbagi menjadi dua yakni numerik dan kategorikal [5]. Variabel numerik diantaranya adalah suhu, kelembapan, kecepatan angin, curah hujan, tekanan atmosfer, indeks UV, serta jarak pandang, sedangkan variabel kategorik adalah tutupan awan, musim, lokasi, dan jenis cuaca yang merupakan label klasifikasi. Kemudian dilakukan pemeriksaan data duplikat serta missing values. Apabila data sudah bersih, maka dilanjutkan dengan perhitungan ringkasan statistik.

Untuk menganalisis tingkat kekuatan hubungan antar variabel diperlukan sebuah metode yang disebut analisis korelasi [24]. Semakin nilai korelasi mendekati satu maka akan semakin tinggi pula kekuatan hubungan antar variabel. Namun, jika nilai korelasi mendekati nol maka semakin rendah kekuatan hubungan antar variabel [7]. Pada penelitian ini metode analisis korelasi yang digunakan adalah korelasi Pearson yang digunakan untuk mengukur tingkat kekuatan hubungan linier antar dua variabel. Tingkat kekuatan hubungan antara variabel

dependen dan variabel independen disimbolkan dengan koefisien korelasi (r) yang berada pada rentang 1 sampai -1 ($-1 \leq r \leq 1$) [9]. Interpretasi koefisien korelasi (r) adalah sebagai berikut [10]:

Tabel 1. Interpretasi koefisien korelasi (r)

Rentang Koefisien	Tingkat Kekuatan Hubungan
0,80 - 1,000	Sangat Kuat
0,60 - 0,799	Kuat
0,40 - 0,599	Cukup Kuat
0,20 - 0,399	Rendah
0,00 - 0,199	Sangat Rendah

Jika nilai koefisien korelasi yang dihasilkan adalah positif, maka kenaikan (penurunan) nilai variabel bebas diikuti dengan kenaikan (penurunan) nilai variabel terikat. Namun, apabila nilai koefisien korelasi yang dihasilkan adalah negatif, maka kenaikan (penurunan) nilai variabel bebas diikuti dengan penurunan (kenaikan) nilai variabel terikat. Persamaan 1 menunjukkan rumus untuk mencari koefisien korelasi Pearson (*Pearson's Product Moment Coefficient of Correlation*) [9]:

$$r = \frac{n \sum_{i=1}^n X_i Y_i - \sum_{i=1}^n X_i \sum_{i=1}^n Y_i}{\sqrt{n \sum_{i=1}^n X_i^2 - \left(\sum_{i=1}^n X_i \right)^2} \sqrt{\sum_{i=1}^n Y_i^2 - \left(\sum_{i=1}^n Y_i \right)^2}} \quad (1)$$

Nilai koefisien r yang didapatkan menggambarkan korelasi antara variabel dependen Y terhadap variabel independen X .

Multikolinearitas merupakan keadaan tidak saling bebas antara variabel bebas [11]. Uji multikolinearitas dilakukan untuk melihat apakah terdapat multikolinearitas antar variabel bebas, karena model regresi yang baik adalah yang tidak terdapat korelasi antar variabel [12]. Jika antar variabel saling berkorelasi, mengindikasikan bahwa model tidak ortogonal [14]. Variabel ortogonal merupakan variabel independen yang memiliki nilai korelasi dengan variabel independen lainnya sebesar nol [14]. Cara untuk mendeteksi multikolinearitas adalah dengan mencari nilai *Variance Inflation Factor* (VIF) dan nilai *Tolerance* (TOL) [13]. Nilai VIF didapatkan dengan persamaan berikut [11]:

$$VIF_j = \frac{1}{1 - R_j^2} \quad (2)$$

R_j^2 merupakan koefisien determinasi antara X_j dan variabel independen lainnya dengan j bernilai 1,2,...,p. Koefisien determinasi berfungsi untuk mengetahui presentasi pengaruh dari variabel independen terhadap variabel dependen yang didapatkan dengan mengkuadratkan koefisien relasi. Persamaan $1 - R_j^2$ disebut juga dengan nilai TOL [11]. Suatu model regresi dikatakan bebas multikolinearitas adalah ketika nilai VIF yang didapatkan adalah kurang dari 10 dan nilai TOL yang didapatkan lebih dari 0,1 [16].

2.3. PREPROCESSING DATA

Preprocessing merupakan bentuk penggalian data (*data mining*) yang bertujuan untuk menggantikan data menyimpang. Metode ini digunakan untuk menyelesaikan masalah pada data yang tidak memadai, tidak konsisten, serta tidak akurat. Terdapat lima tugas utama dari data *preprocessing*, yakni pembersihan data, pengurangan data, menskalakan data, mentransformasi data, serta membagi data [17]. Pada penelitian ini, data

preprocessing terdiri atas tiga tahap, yakni melakukan *label encoding* kemudian menormalisasi data dan diakhiri dengan membagi data menjadi data *training* dan *testing*.

Metode *preprocessing data* yang berfungsi untuk mengubah tipe data yang sebelumnya bertipe numerik menjadi bertipe kategorik disebut dengan *label encoding* [18].

Normalisasi data digunakan untuk membuat atribut dalam data memiliki skala atau rentang nilai yang lebih kecil dengan bobot yang sama. Hal ini dilakukan untuk memaksimalkan kinerja klasifikasi dengan menghapus fitur yang memiliki relevansi rendah serta noise yang tinggi [20]. Metode yang digunakan dalam normalisasi adalah *Z-score normalization*, yang merupakan metode normalisasi dengan persamaan,

$$x' = \frac{x_i - \text{mean}(x)}{\text{std}(x)} \quad (3)$$

X_i merupakan nilai yang akan dilakukan normalisasi, kemudian x' adalah hasil dari normalisasi. Nilai rata-rata dari atribut disimbolkan dengan $\text{mean}(x)$ serta nilai standar deviasi ditandai dengan $\text{std}(x)$. Normalisasi *Z-score* dipilih karena kemampuannya untuk tetap stabil walaupun terdapat outlier [21].

2.4. MEMBANGUN MODEL

2.4.1. Decision Tree


Decision Tree merupakan *supervised machine learning* dimana model akan belajar dari data yang telah memiliki label [30]. Kemampuan *Decision Tree* dalam mengambil keputusan yang kompleks, menjadi sebuah aturan yang mudah dipahami dan menjadikan model ini cukup populer [31]. *Decision Tree* biasanya dimanfaatkan pada penambangan data khususnya klasifikasi [33].

Decision Tree bekerja dengan cara menghitung *entropy* dan *information gain* untuk setiap atribut pada data. Atribut yang memiliki *information gain* tertinggi dipilih menjadi *root node* [32]. Hal tersebut akan selalu berulang hingga atribut pada data dapat menjelaskan secara keseluruhan.

$$\text{Entropy}(S) = \sum_{i=1}^n - p_i * \log_2 p_i \quad (04)$$

$$\text{Gain}(S, A) = \text{Entropy}(S) - \sum_{i=1}^n \frac{|S_i|}{|S|} * \text{Entropy}(S_i) \quad (05)$$

Model *Decision Tree* terdiri dari *nodes* yang merepresentasikan atribut atau kondisi sebagai dasar pengambilan keputusan dan *edge/connection* yang menunjukkan arah klasifikasi atau pembagian data berdasarkan hasil evaluasi kondisi pada simpul tersebut [34]. Setiap simpul akan membagi data ke dalam kelompok yang lebih spesifik, hingga mencapai simpul daun (*leaf nodes*), yang mewakili hasil akhir klasifikasi atau prediksi.




Gambar 3. *Decision Tree*

2.4.2. Random Forest

Random Forest merupakan model *ensemble* yang menggabungkan beberapa *Decision Tree* untuk memecahkan permasalahan yang kompleks sekaligus meningkatkan performa model [35]. Algoritma *Random Forest* bekerja dengan menggabungkan beberapa *Decision Tree* yang telah dibuat dari sampel dataset acak dan menghasilkan hasil dari voting terbanyak dari tiap tiap *Decision Tree* [36].

Salah satu keunggulan utama *Random Forest* adalah penerapan teknik *bagging* (*Bootstrap Aggregating*) untuk membuat *Decision Tree* independen [38]. Hal tersebut membuat model yang memiliki akurasi yang lebih tinggi dan robust atau tahan terhadap data outlier, data noise, serta baik dalam menangani data baru. Dasar dari pembuatan metode klasifikasi ini adalah prinsip bahwa pembuatan beberapa klasifikasi akan memiliki performa lebih baik dari pada sebuah klasifikasi tunggal saja [37].

Dalam menangani data yang sangat besar *Random Forest* memiliki waktu proses yang relatif cepat dan efisien [39]. Hal tersebut dikarenakan setiap *Decision Tree* dibuat secara independen satu sama lain yang memungkinkan *parallel processing*. Data yang diambil secara acak dari dataset utama juga membantu membuat *Decision Tree* sederhana yang tidak membutuhkan semua dataset sehingga waktu komputasi dapat dikurangi.



Gambar 4. *Random Forest*

2.5. OPTIMALISASI MODEL

Grid Search Cross-validation (GSCV) merupakan salah satu metode untuk meningkatkan performa model dengan mencari kombinasi *hyperparameter* yang sesuai [17]. GSCV bekerja dengan cara membuat banyak model yang memiliki *hyperparameter* set yang berbeda-beda. dari percobaan yang dilakukan model yang memiliki hasil yang terbaik akan dipilih sebagai hasil akhir [40].

2.5.1. GRID SEARCH

Grid Search dikembangkan untuk optimasi dari permasalahan yang kompleks dengan cara mencari *hyperparameter* pada jangkauan yang telah ditentukan [41]. Hal ini dilakukan untuk mencari kombinasi *hyperparameter* yang paling sempurna dibandingkan dengan menggunakan nilai bawaan. dengan tuning parameter yang baik maka dapat didapatkan model yang baik dan seimbang [42].


Pada penelitian ini menggunakan beberapa *hyperparameter* antara lain:

- a.) *n_estimators* : Jumlah *decision tree* yang dibuat
- b.) *max_depth* : Kedalaman maksimal *decision tree*
- c.) *min_samples_split* : Jumlah minimal sampel untuk membagi sebuah node

2.5.2. K-FOLD CROSS-VALIDATION

K-Fold Cross Validation adalah metode yang sering dikombinasikan dengan *Grid Search* untuk mengurangi risiko *overfitting* pada model. Teknik ini juga terbukti membuat model menjadi lebih baik dibandingkan model dengan metode lainnya, sebagaimana dilaporkan dalam berbagai literatur [44].

K-Fold Cross Validation bertujuan untuk mengevaluasi seberapa baik model dapat memprediksi data baru yang belum pernah dilihat sebelumnya [45]. Prosesnya melibatkan pembagian data latih menjadi K bagian (*folds*) dengan ukuran yang sama. Secara bergantian, satu bagian digunakan sebagai data uji (*testing set*), sementara bagian lainnya digunakan sebagai data latih (*training set*) [43]. Proses ini diulangi sebanyak K kali sehingga setiap bagian data berperan sebagai data uji sekali. Rata-rata akurasi dari model sebanyak K tersebut akan menjadi skor terakhir yang memberikan gambaran performa model secara keseluruhan [43].




Gambar 5. *K-fold Cross Validation*

2.6. EVALUASI

Pada penelitian ini menggunakan *confusion matrix* untuk mengukur sejauh mana model dapat berjalan dengan baik. *Confusion matrix* merupakan metode yang memberikan informasi hasil dari model klasifikasi yang telah dibuat [46].

Confusion matrix memiliki 4 variabel utama klasifikasi untuk mengukur hasil model [48]:

1. *True Positif* (TP) : Total dari data positif yang diklasifikasikan sebagai nilai positif
2. *False positif* (FP) : Total dari data negatif yang diklasifikasikan sebagai nilai positif
3. *True Negatif* (TN) : Total dari data positif yang di klasifikasikan nilai positif
4. *False Negatif* (FN) : Total dari data negatif yang di klasifikasikan nilai negatif



Gambar 6. *Confusion Matrix*

Keempat variabel ini menjadi dasar untuk menghitung hasil evaluasi model seperti [47]:

1. Akurasi : Proporsi prediksi yang benar terhadap total data.
2. Recall : Kemampuan model mendeteksi data positif dengan benar.
3. Precision : Proporsi prediksi positif yang benar terhadap semua prediksi positif.
4. F1-Score : Rata-rata harmonik antara precision dan recall, mengukur keseimbangan antara keduanya.

$$\text{Akurasi} = \frac{TP+TN}{TP+TN+FP+FN} \quad (06)$$

$$\text{Recall} = \frac{TP}{TP+FN} \quad (07)$$

$$\text{Precision} = \frac{TP}{TP+FP} \quad (08)$$

$$\text{F1-Score} = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (09)$$


3. HASIL DAN PEMBAHASAN

3.1. DATA COLLECTION

Data didapatkan dari situs web *kaggle* dengan tautan <https://www.kaggle.com/datasets/nikhil7280/weather-type-classification>. Parameter data jenis cuaca (*weather type*) meliputi suhu (*temperature*) dalam satuan derajat celcius, kelembapan (*humidity*) dalam satuan persen, kecepatan angin (*wind speed*) dalam satuan kilometer/jam, curah hujan (*precipitation*) dalam satuan persen, tutupan awan (*cloud cover*), tekanan atmosfer (*atmospheric pressure*) dalam satuan hPa, indeks UV (*UV index*), musim (*season*), jarak pandang (*visibility*) dalam satuan kilometer, dan lokasi (*location*).

3.2. DATA ANALYSIS

Pemeriksaan data duplikat bertujuan untuk meningkatkan integritas data dengan mengidentifikasi entri yang muncul lebih dari satu kali. Pemeriksaan null/missing values diperlukan guna menghindari analisis yang tidak efisien [6]. Berdasarkan hasil pemeriksaan, tidak terdapat data duplikat dan tidak terdapat data yang null atau *missing*.



Gambar 7. Keterangan data duplikat

data.isnull().sum()	
	0
Temperature	0
Humidity	0
Wind Speed	0
Precipitation (%)	0
Cloud Cover	0
Atmospheric Pressure	0
UV Index	0
Season	0
Visibility (km)	0
Location	0
Weather Type	0


Gambar 8. Keterangan data null

Tahap berikutnya adalah menganalisis data dengan ringkasan statistik yang terdiri atas jumlah data, mean, standar deviasi, nilai minimum, nilai kuartil bawah, nilai kuartil tengah, nilai kuartil atas, serta nilai maksimum dari masing-masing variabel numerik.

	Temperature	Humidity	Wind Speed	Precipitation (%)	Atmospheric Pressure	UV Index	Visibility (km)
count	13200.000000	13200.000000	13200.000000	13200.000000	13200.000000	13200.000000	13200.000000
mean	19.127578	88.710833	9.832197	53.644394	1005.827898	4.005758	5.462917
std	17.398327	20.194248	6.908704	31.948541	37.199589	3.856600	3.371499
min	-25.000000	20.000000	0.000000	0.000000	800.120000	0.000000	0.000000
25%	4.000000	57.000000	5.000000	19.000000	994.800000	1.000000	3.000000
50%	21.000000	70.000000	9.000000	58.000000	1007.850000	3.000000	5.000000
75%	31.000000	84.000000	13.500000	82.000000	1018.772500	7.000000	7.500000
max	109.000000	109.000000	48.500000	109.000000	1199.210000	14.000000	20.000000

Gambar 9. Ringkasan statistik dataset

Untuk menganalisis tingkat kekuatan hubungan antar variabel, dilakukan pengujian nilai korelasi kekuatan hubungan antar variabel.



Gambar 10. Korelasi antar variabel

Berdasarkan Gambar 10, korelasi yang sangat kuat terdapat pada hubungan antara kelembapan dan curah hujan yakni dengan nilai 0.64 yang menunjukkan bahwa curah hujan dan kelembapan memiliki keterkaitan yang erat dan bergerak searah (positif). Sedangkan korelasi yang sangat rendah terdapat pada hubungan antara indeks UV dan kecepatan angin yakni dengan nilai -0.068 yang berarti bahwa indeks UV dan kecepatan angin berkorelasi negatif.


Tahapan Analisis Data berikutnya adalah pengecekan multikolinearitas. Berdasarkan data yang digunakan, nilai VIF dari masing-masing variabel adalah sebagai berikut:

Tabel 2. Nilai VIF data numerik


Variabel	Nilai VIF
Suhu	1,247460
Kelembapan	1,925919
Kecepatan angin	1,325992
Curah hujan	1,969443
Tekanan atmosfer	1,066599

Index UV	1,346275
Jarak Pandang	1,471022

Nilai VIF yang kurang dari 10 menunjukkan nilai TOL yang lebih dari 0,1. Hal ini mengartikan bahwa tidak ada multikolinearitas yang memengaruhi interpretasi dan kinerja model. Tahapan selanjutnya adalah memvisualisasikan persebaran data pada masing-masing variabel baik numerik maupun kategorik.



Gambar 11. Visualisasi variabel numerik dengan *bar chart*



Gambar 12. Visualisasi variabel kategorik dengan *pie chart*

Persebaran data tutupan awan didominasi oleh jenis *overcast* yakni sebesar 46,1% dan jenis tutupan awan paling sedikit adalah *cloudy* sebesar 3,1%. Distribusi data musim didominasi oleh jenis musim *winter* dengan data sebanyak 42,5% dan jenis musin *autumn* serta *summer* memiliki persebaran data paling sedikit yakni sebesar 18,9%. Pada data yang digunakan terdapat tiga lokasi, yakni *mountain* dan *inland* sebanyak 36,5% serta *coastal* sebanyak 27,1%. Selanjutnya, label yang digunakan dalam data terbagi sama rata yakni jenis cuaca *snowy*, *rainy*, *sunny*, dan *cloudy* sebesar 25%. Jika disajikan dalam bentuk jumlah, maka persebaran data akan menjadi seperti pada tabel dibawah ini:

Tabel 3. Jumlah data masing-masing tutupan awan (*cloud cover*)

Jenis	Jumlah
<i>Overcast</i>	6090
<i>Party Cloudy</i>	4560

<i>Clear</i>	2139
<i>Cloudy</i>	411

Tabel 4. Jumlah data masing-masing musim (*season*)

Jenis	Jumlah data
<i>Winter</i>	5610
<i>Spring</i>	2598
<i>Autumn</i>	2500
<i>Summer</i>	2492

Tabel 5. Jumlah data masing-masing lokasi (*location*)

Jenis	Jumlah data
<i>inland</i>	4816
<i>mountain</i>	4813
<i>coastal</i>	3571

Tabel 6. Jumlah data masing-masing jenis cuaca (*weather type*)

Jenis	Jumlah data
<i>Rainy</i>	3300
<i>Cloudy</i>	3300
<i>Sunny</i>	3300
<i>Snowy</i>	3300

3.3. PREPROCESSING DATA

3.3.1. LABEL ENCODING DAN NORMALISASI DATA

Transformasi data dilakukan untuk mempersiapkan dataset agar dapat digunakan oleh algoritma pembelajaran mesin. Variabel bertipe kategorik dikonversi menjadi format numerik menggunakan Label Encoding. Diantaranya adalah tutupan awan (*cloud cover*), musim (*season*), serta lokasi (*location*). Jenis cuaca (*weather type*) tidak dilakukan *label encoding* karena variabel ini merupakan variabel prediktor yang berperan sebagai label klasifikasi.

	Temperature	Humidity	Wind Speed	Precipitation (%)	Cloud Cover	Atmospheric Pressure	UV Index	Season	Visibility (km)	Location	Weather Type
0	14.0	73	9.5	82.0	3	1010.82	2	3	3.5	1	Rainy
1	39.0	96	8.5	71.0	3	1011.43	7	1	10.0	1	Cloudy
2	30.0	64	7.0	16.0	0	1018.72	5	1	5.5	2	Sunny
3	38.0	83	1.5	82.0	0	1026.25	7	1	1.0	0	Sunny
4	27.0	74	17.0	66.0	2	990.67	1	3	2.5	2	Rainy

Gambar 13. Hasil *label encoding* untuk variabel kategorik

Setelah itu, data dinormalisasi untuk menghilangkan skala yang tidak seragam. Proses ini bertujuan untuk meningkatkan efektivitas model dalam memproses data.

Temperature	Humidity	Wind Speed	Precipitation (%)	Cloud Cover	Atmospheric Pressure	UV Index	Season	Visibility (km)	Location
-0.294931	0.212404	-0.048088	0.887629	0.997539	0.134203	-0.520104	0.987831	-0.582231	-0.118893
1.143035	1.351385	-0.192836	0.543291	0.997539	0.150802	0.776424	-0.729231	1.345768	-0.118893
0.625367	-0.233285	-0.409962	-1.178401	-1.986116	0.346579	0.257813	-0.729231	0.010999	1.144706
1.085516	0.707613	-1.206089	0.887629	-1.986116	0.549008	0.776424	-0.729231	-1.323769	-1.382492
0.452811	0.261924	1.037543	0.386773	0.009654	-0.407490	-0.779410	0.987831	-0.878846	1.144706

Gambar 14. Lima baris pertama dataset hasil normalisasi

3.3.2. PEMBAGIAN DATA LATIH DAN DATA UJI

Tahap terakhir dari *data preprocessing* adalah membagi data menjadi *training* dan *testing*. Data yang digunakan untuk mempermudah model dalam mengekstraksi data untuk mengambil keputusan, disebut dengan data *training* yang kemudian data *training* ini dilatih agar mampu mendapatkan pengetahuan baru [22]. Sedangkan, data *testing* adalah data yang digunakan sebagai bahan uji setelah model dilatih menggunakan data *training* [23]. Pada penelitian ini, 80% data atau sejumlah 10560 data dari keseluruhan dataset dibuat sebagai data *training* sedangkan 20% data atau sejumlah 2640 data menjadi data *testing*.

3.4. PENGUJIAN MODEL

Pengujian dilakukan untuk mengevaluasi performa model Decision Tree dan Random Forest dalam memprediksi data uji secara menyeluruh.

Tabel 3. Hasil Classification Report Model Decision Tree

Weather Condition	Precision	Recall	F1-Score
Cloudy	0.8705	0.8879	0.8791
Rainy	0.8997	0.8872	0.8934
Snowy	0.9337	0.9444	0.9390
Sunny	0.9205	0.9033	0.9118
Accuracy			0.9064

Model *Decision Tree* mencapai akurasi total sebesar 90,64%. Hal ini menunjukkan bahwa model secara keseluruhan memiliki kinerja yang akurat dan stabil dalam mendeteksi berbagai kondisi cuaca.

Tabel 4. Hasil Classification Report Model Random Forest

Weather Condition	Precision	Recall	F1-Score
Cloudy	0.8674	0.8940	0.8805
Rainy	0.9112	0.904	0.9077

Snowy	0.9309	0.9415	0.9362
Sunny	0.9304	0.8970	0.9134
Accuracy			0.9098

Terdapat sedikit peningkatan pada model Random Forest yang mencapai akurasi total sebesar 90,98%. Ini menunjukkan bahwa performa model tetap konsisten dan ada sedikit peningkatan pada beberapa kategori.

3.5. PENGOPTIMALAN MODEL

Optimisasi dilakukan menggunakan GridSearchCV dengan berbagai kombinasi parameter. Proses ini bertujuan untuk menemukan konfigurasi parameter yang menghasilkan akurasi tertinggi melalui validasi silang atau *cross validation*. Parameter yang digunakan dalam penelitian ini adalah sebagai berikut:

- n_estimators: [50, 100, 200]
- max_depth: [10, 20, 30]
- min_samples_split: [2, 5, 10]

GridSearchCV akan mencoba semua kombinasi parameter untuk dilakukan pengujian pada model Random Forest. Sehingga akan ditemukan peringkat kombinasi parameter terbaik yang diuji.

Tabel 5. 5 Kombinasi Parameter terbaik hasil GridSearchCV

n_estimators	max_depth	min_samples_split	mean_test_score	rank_test_score
100	30	10	0.917330	1
100	20	10	0.917140	2
100	30	5	0.916667	3
100	20	5	0.916477	4
200	20	10	0.916288	5


Setelah itu, dilakukan pengujian Random Forest menggunakan ke lima kombinasi parameter terbaik yang telah ditemukan :

- Akurasi GSCV 1 : 0.915530303030303
- Akurasi GSCV 2 : 0.9162878787878788
- Akurasi GSCV 3 : 0.9117424242424242
- Akurasi GSCV 4 : 0.9143939393939394
- Akurasi GSCV 5 : 0.9143939393939394

Dari hasil tersebut, ditemukan kombinasi parameter terbaik dari Random Forest dengan akurasi terbesar yaitu 91,63% dengan parameter n_estimator : 100, max_depth : 20, dan min_sample_split : 10.

3.6. PERBANDINGAN MODEL

Setelah memodelkan algoritma Decision Tree, Random Forest, dan Random Forest yang dioptimalkan menggunakan GridSearchCV (GSCV), dilakukan analisis menggunakan Confusion Matrix untuk menunjukkan hasil perbandingan kinerja masing-masing model. Hal ini dilakukan untuk memberikan gambaran detail tentang bagaimana setiap model memprediksi setiap kelas, termasuk jumlah prediksi benar (true positives dan true negatives) serta jumlah kesalahan (false positives dan false negatives).



Gambar 7. Perbandingan Confusion Matrix Ketiga Model

Confusion Matrix diatas menunjukkan bahwa Decision Tree memiliki kesalahan prediksi lebih tinggi dibandingkan Random Forest dan Random Forest yang dioptimalkan dengan GridSearchCV. Random Forest berhasil mengurangi kesalahan prediksi di semua kelas, sementara Random Forest (GSCV) memberikan hasil terbaik dengan distribusi prediksi yang lebih akurat dan jumlah kesalahan paling rendah, terutama pada kelas Snowy dan Sunny. Hal ini membuktikan bahwa optimisasi menggunakan GridSearchCV meningkatkan kinerja model secara signifikan dibandingkan dua model lainnya.

Tabel 5. 6 Perbandingan Model Hasil

Model	Akurasi
Decision Tree	0.906439393939394
SVM	0.9068181818181819
KNN	0.8920454545454546
Logistic Regression	0.8484848484848485
Naive Bayes	0.8628787878787879
Random Forest	0.9098484848484848
Random Forest GSCV	0.9162878787878788

Pada penelitian ini telah menemukan bahwa model yang telah dibuat memiliki akurasi yang lebih baik dari model-model lainnya. Pengoptimalan menggunakan *Grid Search Cross Validation* telah meningkatkan akurasi *random forest* dari 0.9098484 menjadi 0.9162878. *Random Forest* yang telah dioptimalkan menggunakan *Grid Search Cross Validation* memiliki akurasi sebesar 0.9162878 yang mana telah berhasil mengungguli akurasi dari model yang dibuat dengan metode lain seperti, SVM, KNN, Logistic Regression, dan Naive Bayes. Hal tersebut mengindikasikan bahwa *Random Forest Grid Search Cross Validation* merupakan model terbaik untuk memprediksi klasifikasi cuaca.

4. KESIMPULAN

Penelitian ini menunjukkan bahwa prediksi cuaca dapat ditingkatkan secara signifikan melalui penerapan algoritma *Decision Tree* yang dioptimalkan dengan *Random Forest* dan *Grid Search Cross-Validation*. Algoritma *Decision Tree* awalnya menghasilkan tingkat akurasi sebesar 90,64%. Dengan menggunakan *Random Forest*, akurasi meningkat menjadi 90,98%. Optimasi hyperparameter melalui *Grid Search Cross-Validation* lebih lanjut meningkatkan akurasi menjadi 91,63%.

Hasil ini membuktikan bahwa metode *Random Forest* dengan hyperparameter terbaik, yaitu *n_estimators* : 100, *max_depth* : 20, dan *min_samples_split* : 10, memberikan performa model yang lebih baik dibandingkan *Decision Tree*. Model ini menunjukkan kemampuan generalisasi yang lebih tinggi, sehingga lebih andal untuk digunakan dalam memprediksi cuaca.

Secara keseluruhan, penelitian ini berhasil mencapai tujuan utama untuk mengoptimalkan algoritma *Decision Tree* menggunakan *Random Forest* melalui pendekatan ensemble learning dan tuning parameter, yang menghasilkan model prediksi cuaca yang akurat dan dapat diandalkan. Penggunaan metode ini diharapkan dapat membantu berbagai sektor yang bergantung pada prediksi cuaca, seperti transportasi, agrikultur, dan mitigasi bencana.

5. REFERENSI

- [1] Siregar, A. M. (2020). Klasifikasi Untuk Prediksi Cuaca Menggunakan Esemble Learning. *Petir*, 13(2), 522-607.
- [2] Husin, N. (2023). Komparasi Algoritma Random Forest, Naïve Bayes, dan Bert Untuk Multi-Class Classification Pada Artikel Cable News Network (CNN). *J. Esensi Infokom J. Esensi Sist. Inf.*
- [3] Matin, I. M. M. (2023). Hyperparameter Tuning Menggunakan GridsearchCV pada Random Forest untuk Deteksi Malware. *MULTINETICS*, 9(1), 43-50.
- [4] Hindrayani, K. M. (2022, November). Analisa Pekerjaan Sains Data di Australia menggunakan Pendekatan Exploratory Data Analysis. In *PROSIDING SEMINAR NASIONAL SAINS DATA* (Vol. 2, No. 1, pp. 76-82).
- [5] Nissa, N. K., Nugraha, Y., Finola, C. F., Ernesto, A., Kanggrawan, J. I., & Suherman, A. L. (2020). Evaluasi berbasis data: Kebijakan pembatasan mobilitas publik dalam mitigasi persebaran Covid-19 di Jakarta. *Jurnal Sistem Cerdas*, 3(2), 84-94.
- [6] Prasetya, M. R. A., & Priyatno, A. M. (2023). Penanganan Imputasi Missing Values pada Data Time Series dengan Menggunakan Metode Data Mining. *Jurnal Informasi dan Teknologi*, 52-62.
- [7] Windarto, Y. E. (2020). Analisis penyakit kardiovaskular menggunakan metode korelasi pearson, spearman dan kendall. *Jurnal Saintekom: Sains, Teknologi, Komputer dan Manajemen*, 10(2), 119-127.
- [8] Yanti, C. A., & Akhri, I. J. (2021). Perbedaan uji korelasi pearson, spearman dan kendall tau dalam menganalisis kejadian diare. *Jurnal Endurance*, 6(1), 51-58.
- [9] Budiwati, T., Budiyono, A., Setyawati, W., & Indrawati, A. (2010). Analisis korelasi pearson untuk unsur-unsur kimia air hujan di Bandung. *Jurnal Sains Dirgantara*, 7(2).
- [10] Wijayanto, A. (2008). Analisis Korelasi Product Moment Pearson.
- [11] Sriningsih, M., Hatidja, D., & Prang, J. D. (2018). Penanganan multikolinearitas dengan menggunakan analisis regresi komponen utama pada kasus impor beras di Provinsi Sulut. *Jurnal Ilmiah Sains*, 18(1), 18-24.
- [12] Kasenda, R. (2013). Kompensasi dan motivasi pengaruhnya terhadap kinerja karyawan pada PT. Bangun Wenang Beverages Company Manado. *Jurnal EMBA: Jurnal Riset Ekonomi, Manajemen, Bisnis dan Akuntansi*, 1(3).
- [13] Putri, A. D., & Setiawina, D. (2013). Pengaruh umur, pendidikan, pekerjaan terhadap pendapatan rumah tangga miskin di Desa Bebandem. *E-Jurnal Ekonomi Pembangunan Universitas Udayana*, 2(4), 44604.
- [14] Chasanah, A. N., & Adhi, D. K. (2018). Profitabilitas, struktur modal dan likuiditas pengaruhnya terhadap nilai perusahaan pada perusahaan real estate yang listed di BEI tahun 2012-2015. *Fokus Ekonomi: Jurnal Ilmiah Ekonomi*, 12(2), 109-128.
- [15] Dewi, S. P. (2012). Pengaruh pengendalian internal dan gaya kepemimpinan terhadap kinerja karyawan SPBU Yogyakarta (studi kasus pada spbu anak cabang perusahaan RB. Group). *Nominal Barometer Riset Akuntansi dan Manajemen*, 1(1).
- [16] Shabrina, N., Darmadi, D., & Sari, R. (2020). Pengaruh Motivasi dan Stres Kerja Terhadap Kinerja Karyawan CV. Muslim Galeri Indonesia. *Jurnal Madani: Ilmu Pengetahuan, Teknologi, Dan Humaniora*, 3(2), 164-173.
- [17] Putra, A. F. D., Azmi, M. N., Wijayanto, H., Utama, S., & Wirawan, I. G. P. W. W. (2024). Optimizing Rain Prediction Model Using Random Forest and Grid Search Cross-Validation for Agriculture Sector. *MATRIK: Jurnal Manajemen, Teknik Informatika dan Rekayasa Komputer*, 23(3), 519-530.
- [18] Dachi, J. M. A. S., & Sitompul, P. (2023). Analisis Perbandingan Algoritma XGBoost dan Algoritma Random Forest Ensemble Learning pada Klasifikasi Keputusan Kredit. *JURNAL RISET RUMPUN MATEMATIKA DAN ILMU PENGETAHUAN ALAM*, 2(2), 87-103.
- [19] Hanafiah, A., Arta, Y., Nasution, H. O., & Lestari, Y. D. (2023). Penerapan Metode Recurrent Neural Network dengan Pendekatan Long Short-Term Memory (LSTM) Untuk Prediksi Harga Saham. *Bulletin of Computer Science Research*, 4(1), 27-33.
- [20] Permana, I., & Salisah, F. N. S. (2022). Pengaruh Normalisasi Data Terhadap Performa Hasil Klasifikasi Algoritma Backpropagation: The Effect of Data Normalization on the Performance of the Classification Results of the Backpropagation Algorithm. *Indonesian Journal of Informatic Research and Software Engineering (IJIRSE)*, 2(1), 67-72.

- [21] Suryanegara, G. A. B., & Purbolaksono, M. D. (2021). Peningkatan Hasil Klasifikasi pada Algoritma Random Forest untuk Deteksi Pasien Penderita Diabetes Menggunakan Metode Normalisasi. *Jurnal RESTI (Rekayasa Sistem Dan Teknologi Informasi)*, 5(1), 114-122.
- [22] Nurkhasanah, K., Sari, M. P., & Fazry, T. R. (2019). Perbandingan Hasil Penggunaan Metode Decision Tree Dan Random Tree Pada Data Training Aplikasi Pencarian Tukang. *Ultima InfoSys: Jurnal Ilmu Sistem Informasi*, 10(2), 93-97.
- [23] Anggraini, R. A., Widagdo, G., Budi, A. S., & Qomaruddin, M. (2019). Penerapan Data Mining Classification untuk Data Blogger Menggunakan Metode Naïve Bayes. *JUSTIN (Jurnal Sistem dan Teknologi Informasi)*, 7(1), 47-51.
- [24] Haryadi, R. (2016). Korelasi antara matematika dasar dengan fisika dasar. *Jurnal Penelitian Dan Pembelajaran Matematika*, 9(1).
- [25] Sidik, A. D., & Ansawarman, A. (2022). Prediksi jumlah kendaraan bermotor menggunakan machine learning. *Formosa Journal of Multidisciplinary Research*, 1(3), 559-568.
- [26] Tangkelayuk, A. (2022). The Klasifikasi Kualitas Air Menggunakan Metode KNN, Naïve Bayes, dan Decision Tree. *JATISI (Jurnal Teknik Informatika Dan Sistem Informasi)*, 9(2), 1109-1119.
- [27] Syahputri, Cindy Novi, & Hasibuan, Muhammad Siddik (2024). OPTIMASI KLASIFIKASI Decision Tree DENGAN TEKNIK PRUNING UNTUK MENGURANGI OVERFITTING.
- [28] Winanto, Eko Arip, Novianto, Yudit, Sharipuddin, Sharipuddin, Wijaya, Ibnu Sani, & Jusia, Pareza Alam (2024). PENINGKATAN PERFORMA DETEKSI SERANGAN MENGGUNAKAN METODE PCA DAN Random Forest.
- [29] Azhari, I. C., & Haryanto, T. (2024). Modeling Of Hyperparameter Tuned RNN-LSTM and Deep Learning For Garlic Price Forecasting In Indonesia. *JOURNAL OF INFORMATICS AND TELECOMMUNICATION ENGINEERING*, 7(2), 502-513.
- [30] Itzkin, M., Palmsten, M. L., Buckley, M. L., Birchler, J. J., & Torres-Garcia, L. M. (2025). Developing a Decision Tree model to forecast runoff and assess uncertainty in empirical formulations. *Coastal Engineering*, 195, 104641.
- [31] Damanik, I. S., Windarto, A. P., Wanto, A., Poningsih, Andani, S. R., & Saputra, W. (2019, August). Decision Tree optimization in C4. 5 algorithm using genetic algorithm. In *Journal of Physics: Conference Series* (Vol. 1255, No. 1, p. 012012). IOP Publishing.
- [32] Pradipta, A., Hartama, D., Wanto, A., Saifullah, S., & Jalaluddin, J. (2019). The Application of Data Mining in Determining Timely Graduation Using the C45 Algorithm. *IJISTECH (International Journal of Information System and Technology)*, 3(1), 31-36.
- [33] Gavankar, S. S., & Sawarkar, S. D. (2017, April). Eager Decision Tree. In *2017 2nd International Conference for Convergence in Technology (I2CT)* (pp. 837-840). IEEE.
- [34] Charbuty, B., & Abdulazeez, A. (2021). Classification based on Decision Tree algorithm for machine learning. *Journal of Applied Science and Technology Trends*, 2(01), 20-28..
- [35] Ishengoma, F. S., & Lyimo, N. N. (2024). Ensemble Model for Grape Leaf Disease Detection using CNN Feature Extractors and Random Forest Classifier. *Heliyon*, e33377..
- [36] Sinambela, D. P., Naparin, H., Zulfadhilah, M., & Hidayah, N. (2023). Implementasi Algoritma Decision Tree dan Random Forest dalam Prediksi Perdarahan Pascasalin. *Jurnal Informasi dan Teknologi*, 58-64.
- [37] Rodriguez-Galiano, V. F., Ghimire, B., Rogan, J., Chica-Olmo, M., & Rigol-Sanchez, J. P. (2012). An assessment of the effectiveness of a Random Forest classifier for land-cover classification. *ISPRS journal of photogrammetry and remote sensing*, 67, 93-104..
- [38] Dietterich, T. G. (2000). An experimental comparison of three methods for constructing ensembles of Decision Trees: Bagging, boosting, and randomization. *Machine learning*, 40, 139-157..
- [39] Breiman, L. (2001). Random Forests. *Machine learning*, 45, 5-32.
- [40] M. Adnan, A. A. S. Alarood, M. I. Uddin, and I. ur Rehman, "Utilizing grid search cross-validation with adaptive boosting for augmenting performance of machine learning models," *PeerJ Computer Science*, vol. 8, no. 1, pp. 1–29, 2022

- [41] Yan, T., Shen, S. L., Zhou, A., & Chen, X. (2022). Prediction of geological characteristics from shield operational parameters by integrating grid search and K-fold cross validation into stacking classification algorithm. *Journal of Rock Mechanics and Geotechnical Engineering*, 14(4), 1292-1303..
- [42] Abas, M. A. H., Ismail, N., Ali, N. A., Tajuddin, S., & Tahir, N. M. (2020). Agarwood oil quality classification using support vector classifier and Grid Search Cross Validation hyperparameter tuning. *Int. J.*, 8(10.30534).
- [43] Rodriguez, J. D., Perez, A., & Lozano, J. A. (2009). Sensitivity analysis of k-fold cross validation in prediction error estimation. *IEEE transactions on pattern analysis and machine intelligence*, 32(3), 569-575..
- [44] Ünal, S., Günay, O., Akkurt, I., Gunoglu, K., & Tekin, H. O. (2024). A comparative study on breast cancer classification with stratified shuffle split and K-fold cross validation via ensembled machine learning. *Journal of Radiation Research and Applied Sciences*, 17(4), 101080.
- [45] Ali, N. M., Besar, R., & Ab Aziz, N. A. (2023). A case study of microarray breast cancer classification using machine learning algorithms with Grid Search Cross Validation. *Bulletin of Electrical Engineering and Informatics*, 12(2), 1047-1054..
- [46] Rahman, M. F., Alamsah, D., Darmawidjadja, M. I., & Nurma, I. (2017). Klasifikasi untuk diagnosa diabetes menggunakan metode bayesian regularization neural network (rbnn). *Jurnal Informatika*, 11(1), 36..
- [47] Matrix, C., Model, M. L., Descent, S. G., Sanjaya, M. O., No, J. K. T., Timur, K., & Summersari, K. J. (2023). Virtual Assistant for Thesis Technical Guide Using Artificial Neural Network. *Indonesian Journal of Artificial Intelligence and Data Mining (IJAIMD)*, 6(2), 188-196.
- [48] Apriyani, H., & Kurniati, K. (2020). Perbandingan Metode Naïve Bayes Dan Support Vector Machine Dalam Klasifikasi Penyakit Diabetes Melitus. *Journal of Information Technology Ampera*, 1(3), 133-143.